

Métodos de Segmentação e Reconhecimento de Imagens Aplicados ao Diagnóstico da Doença de Alzheimer

Brenno Augusto H. dos Santos¹, Eduardo Oliveira Coelho¹,
Felipe Tadeu Góes Guimarães¹, Felipe Lacerda Tertuliano¹

¹ Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Curso de Ciência da Computação
Belo Horizonte – MG – Brasil

1398150@sga.pucminas.br, 1334354@sga.pucminas.br,
1017035@sga.pucminas.br, 1265214@sga.pucminas.br

Abstract. *This study analyzes structural brain changes in Alzheimer's disease using 360 coronal MRI images from the OASIS-2 dataset. Lateral ventricles were segmented, morphological features extracted, and models including Linear Regression, XGBoost, and ResNet50 were applied. Results show that both extracted features and deep representations effectively distinguish Demented from NonDemented subjects, highlighting the potential of image-based computational analysis for diagnosis.*

Resumo. *Este estudo analisa alterações cerebrais na Doença de Alzheimer em 360 imagens coronais do dataset OASIS-2. Foram segmentados os ventrículos laterais, extraídas características morfológicas e aplicados modelos como Regressão Linear, XGBoost e ResNet50. Os resultados indicam que tanto as características extraídas quanto as representações profundas distinguem eficazmente indivíduos Demented e NonDemented, evidenciando o potencial de análises computacionais para o diagnóstico.*

1. Introdução

O diagnóstico da Doença de Alzheimer (DA) envolve a identificação de alterações estruturais no cérebro, especialmente em regiões relacionadas à perda de massa encefálica e dilatação dos ventrículos laterais. Assim como ocorre no envelhecimento natural, a progressão da DA está associada a mudanças volumétricas mensuráveis em diversas estruturas neurológicas. O objetivo deste trabalho é analisar imagens de ressonância magnética (MRI) de pacientes saudáveis e com diferentes graus de comprometimento cognitivo, aplicando métodos de segmentação e reconhecimento de padrões para auxiliar a diferenciação entre indivíduos Demented e NonDemented.

A partir das imagens selecionadas, foram implementadas técnicas de segmentação dos ventrículos laterais e extração de características morfológicas, seguidas pela aplicação de classificadores rasos e profundos para reconhecer padrões relacionados à demência. Além disso, modelos de regressão foram utilizados para estimar a idade dos pacientes no momento do exame, permitindo analisar o efeito do envelhecimento natural e da doença sobre as estruturas cerebrais.

2. Descrição do Dataset e das Partições

O dataset utilizado corresponde a um subconjunto do *OASIS-2 Dataset*, constituído por imagens de ressonância magnética ponderadas em T1 de indivíduos entre 60 e 96 anos. O conjunto contém 150 pacientes avaliados longitudinalmente, totalizando 373 sessões de imagem. Cada volume original no formato NIfTI foi pré-processado para extração do cérebro, normalização e registro afim ao atlas MNI152, sendo então convertidos para imagens em 8 bits.

Para este trabalho, a configuração definida pelo grupo foi determinada conforme as regras estabelecidas pelo professor:

- **DS = 2:** O dataset selecionado foi o plano **axial**.
- **NR = 0:** O regressor raso é o **Regressor Linear**.
- **NC = 0:** O classificador raso adotado é o **XGBoost**.
- **ND = 0:** O classificador/regressor profundo utilizado é a rede **ResNet50**.

Durante a etapa de inspeção inicial dos dados, foram identificadas 13 imagens cujo conteúdo visual apresentava discrepâncias significativas em relação ao padrão geral do conjunto, indicando problemas de pré-processamento ou deformações anatômicas não condizentes com as demais amostras. Essas 13 imagens foram removidas para evitar ruído nos experimentos. Como o dataset original possui 373 imagens, a remoção não alterou substancialmente o tamanho do conjunto nem afetou a diversidade demográfica ou a distribuição das classes. Assim, a análise final foi conduzida com 360 imagens válidas.

A divisão do dataset seguiu rigorosamente as especificações fornecidas: os pacientes foram separados aleatoriamente em proporção 80% para treino e 20% para teste, garantindo que todas as visitas de um mesmo paciente permanecessem no mesmo conjunto. Além disso, 20% do conjunto de treino foi reservado para validação. A classe *Converted* foi redistribuída conforme o valor de CDR: exames com CDR = 0 foram incorporados à classe *NonDemented*, enquanto exames com CDR > 0 foram movidos para a classe *Demented*. Para evitar desbalanceamento, ambas as classes foram divididas obedecendo à proporção 4:1 entre treino e teste.

3. Metodologia

Esta seção descreve, de forma detalhada, todas as etapas que compõem o pipeline desenvolvido para análise das imagens de ressonância magnética. O processo inclui pré-processamento, segmentação dos ventrículos laterais, extração de descritores morfológicos, divisão dos dados por paciente e aplicação de diferentes modelos de classificação e regressão. Todas as etapas foram implementadas em Python e integradas à interface gráfica desenvolvida para o projeto, permitindo a execução completa do sistema pelo usuário.

O fluxo metodológico combina técnicas clássicas de processamento de imagens com métodos modernos de aprendizado de máquina. Enquanto o pré-processamento e a segmentação permitem extrair informações anatômicas relevantes, os modelos rasos utilizam descritores morfológicos como entrada, e as redes profundas aprendem representações diretamente da textura e geometria das imagens.

3.1. Pré-processamento das imagens

O pré-processamento teve como objetivo uniformizar a qualidade visual das imagens e realçar estruturas anatômicas relevantes, em especial a região ventricular. Após a leitura das imagens NIfTI, utilizou-se automaticamente o corte axial central, definido segundo o parâmetro DS=2 atribuído ao grupo.

Para compensar variações de intensidade comuns em exames de ressonância magnética ponderados em T1, aplicou-se o algoritmo CLAHE (Contrast Limited Adaptive Histogram Equalization), com clip limit 2.0 e janela 8×8. O CLAHE foi escolhido por sua capacidade de melhorar o contraste local sem amplificar ruído, sendo particularmente útil para evidenciar limites anatômicos sem deformar a estrutura.

Dependendo da qualidade visual de cada imagem, filtros adicionais — como mediana, bilateral ou gaussiano — podiam ser aplicados pelo usuário. Essas operações auxiliam na remoção de ruídos de alta granularidade que poderiam prejudicar a etapa de segmentação baseada em intensidade. O sistema armazena o histórico de operações, permitindo desfazer transformações sem comprometer o fluxo de trabalho.

3.2. Segmentação dos ventrículos laterais

A segmentação dos ventrículos laterais foi realizada por meio de region growing, técnica especialmente adequada para estruturas anatômicas homogêneas em intensidade, como as regiões de líquido no interior dos ventrículos. As sementes iniciais foram posicionadas automaticamente em coordenadas correspondentes à anatomia média dos ventrículos no plano axial, podendo ser ajustadas pelo usuário em caso de variações individuais.

O crescimento regional utilizou conectividade-4, garantindo maior continuidade espacial e reduzindo falhas na identificação das bordas internas do ventrículo. A expansão ocorreu até que a diferença de intensidade atingisse um limiar configurável. Um mecanismo de validação automática foi implementado para detectar vazamentos: quando a área ultrapassava um limite plausível para a anatomia ventricular, o sistema substituiu o resultado por uma segmentação alternativa via watershed combinada à transformada de distância, técnica robusta para separar regiões adjacentes de baixa textura.

Para refinar a máscara obtida, aplicaram-se operações morfológicas:

- **Abertura morfológica:** remove pequenos ruídos isolados;
- **Preenchimento de buracos:** garante regiões internas contínuas;
- **Suavização dos contornos:** usando approxPolyDP, reduz serrilhamento e aproxima a máscara a uma geometria mais realista.

O resultado é uma máscara binária limpa e coerente com o formato anatômico dos ventrículos, utilizada tanto para visualização quanto para a extração das características morfológicas.

3.3. Extração de características morfológicas

A análise morfológica dos ventrículos foi realizada com a biblioteca scikit-image, usando a função regionprops, que computa automaticamente diferentes descritores geométricos. Esses descritores servem como entrada para os modelos rasos de classificação e regressão.

Os atributos selecionados foram:

- **Área, Perímetro e Circularidade:** representando propriedades básicas da região segmentada;
- **Excentricidade:** derivada dos momentos de segunda ordem, indicando grau de alongamento da região;
- **Solidez:** razão entre a área segmentada e a área do fecho convexo, útil para detectar irregularidades;
- **Extent:** proporção entre a área da região e a área da bounding box mínima;
- **Aspect Ratio:** relação entre os eixos maior e menor da elipse ajustada.

Essas características foram consolidadas em arquivos CSV e utilizadas tanto para análise exploratória — como geração de scatterplots — quanto como entrada para os modelos de aprendizado de máquina.

3.4. Divisão dos dados e controle por paciente

A divisão dos dados seguiu rigorosamente o princípio de separação por paciente, impedindo que diferentes exames do mesmo indivíduo fossem distribuídos entre treino e teste. Essa estratégia evita vazamento de informação e garante uma avaliação mais justa da capacidade de generalização dos modelos.

O particionamento foi realizado com `GroupShuffleSplit`, resultando em 80% dos pacientes para treino e 20% para teste. Do conjunto de treino, 20% foram reservados para validação. A classe `Converted` foi redistribuída com base no valor de CDR: exames com $CDR=0$ foram incorporados à classe `NonDemented`, enquanto $CDR>0$ foram realocados para `Demented`. O balanceamento final entre as classes seguiu uma proporção aproximada de 4:1 entre treino e teste.

3.5. Classificação

A tarefa de classificação foi conduzida com dois modelos: um raso baseado em descritores morfológicos e um modelo profundo baseado diretamente nas imagens.

3.5.1. Classificador raso (XGBoost)

Para a classificação baseada em características morfológicas, foi utilizado o algoritmo XGBoost, que implementa gradient boosting sobre árvores de decisão. Esse método combina uma sequência de “árvores fracas”, cada uma corrigindo os erros das anteriores. A estratégia de boosting é especialmente eficaz para dados tabulares, pois aprende relações não lineares entre as variáveis e incorpora mecanismos internos de regularização para controlar sobreajuste.

Os descritores foram normalizados com `StandardScaler`, garantindo que diferenças de escala não influenciassem indevidamente o processo de boosting. Em seguida, utilizou-se `RandomizedSearchCV` para otimizar hiperparâmetros como profundidade das árvores, taxa de aprendizado e número de estimadores.

O modelo final foi avaliado no conjunto de teste usando métricas exigidas pelo trabalho: acurácia, sensibilidade, especificidade e matriz de confusão. Essa abordagem raso serve como linha de base para comparação com o classificador profundo.

3.5.2. Classificador profundo (ResNet50)

Para classificação baseada em imagens, adotou-se a ResNet50 pré-treinada na ImageNet, conforme o parâmetro ND=0. As ResNets introduzem conexões residuais (skip connections) que permitem treinar redes profundas sem o problema clássico de degradação do gradiente. Esse mecanismo facilita a aprendizagem de funções complexas e foi decisivo para o bom desempenho em tarefas de visão computacional.

As imagens foram convertidas para 224×224 pixels, normalizadas e replicadas para três canais. A head do modelo foi adaptada com Global Average Pooling, seguida de uma camada densa intermediária e uma camada final com ativação sigmoideal.

O treinamento ocorreu em duas fases:

- **Congelamento do backbone:** apenas a head é treinada, garantindo estabilidade na inicialização.;
- **Fine-tuning parcial:** camadas superiores do backbone são gradualmente descongeladas, permitindo adaptação aos padrões específicos de imagens médicas.

Esse processo híbrido permite combinar a robustez de pesos pré-treinados com especialização na anatomia do cérebro humano.

3.6. Regressão

Com o objetivo de prever a idade do paciente no momento do exame, foram implementados e avaliados modelos de regressão que utilizam como entrada tanto as características morfológicas quanto as informações disponíveis sobre o indivíduo. Esta abordagem permite investigar a relação entre os padrões identificados nas imagens e nos dados com o processo de envelhecimento, fornecendo um método quantitativo para a estimativa.

3.6.1. Regressor Raso (Linear Regression)

Para estabelecer uma linha de base interpretável e computacionalmente eficiente, um modelo de Regressão Linear foi implementado. A escolha deste modelo justifica-se pela sua simplicidade, que facilita a interpretação dos resultados, e pela sua velocidade de treinamento, servindo como um ponto de comparação fundamental para avaliar a eficácia de métodos subsequentes mais complexos.

A implementação consistiu em um *pipeline* do Scikit-learn, que integrou duas etapas sequenciais: (1) um *StandardScaler*, para a normalização das *features*, garantindo que todas as variáveis contribuíssem igualmente para o modelo, e (2) o estimador *LinearRegression*. A utilização de um *pipeline* assegurou a aplicação consistente da normalização, prevenindo o vazamento de dados, uma vez que os parâmetros de escala foram calculados exclusivamente a partir do conjunto de treinamento. Como entrada, o modelo utilizou os mesmos descritores morfológicos dos ventrículos laterais extraídos para as tarefas de classificação, tendo como variável alvo (*target*) a coluna "Age" do *dataset*, que representa a idade do paciente no momento do exame.

O desempenho do regressor foi quantificado por meio de três métricas: o *Erro Absoluto Médio (MAE)* e a *Raiz do Erro Quadrático Médio (RMSE)*, ambas expressas

em anos para avaliar a magnitude do erro de predição, e o *Coefficiente de Determinação* (R^2), que mede a proporção da variância na idade que é explicável pelas características dos ventrículos.

Foram realizadas duas análises automáticas sobre os resultados. A primeira, de *Suficiência das Características*, buscou verificar se os descritores extraídos contêm informação suficiente para prever a idade. Esta análise foi programada para classificar o poder preditivo como *ACEITÁVEL* caso o MAE fosse inferior a 5 anos e o R^2 superior a 0,3; caso contrário, o resultado foi considerado *FRACO*. A segunda análise, de *Monotonicidade da Idade*, verificou a consistência temporal dos dados, agrupando os exames por "patient_id" e checando se a idade dos pacientes aumentava monotonicamente em exames posteriores (ordenados por "Visit" ou "MR Delay"). Violações a essa regra, indicando idades decrescentes, foram reportadas para investigação de possíveis causas, como erros de entrada de dados ou inconsistências entre fontes.

Para visualização dos resultados, foi gerado um gráfico de dispersão (*Predito vs. Real*), onde uma linha diagonal representa as predições perfeitas. Os pontos, representando exames individuais, foram coloridos de acordo com o seu conjunto (treino, validação ou teste), permitindo uma avaliação visual imediata do desempenho e da possível existência de *overfitting* do modelo.

Em síntese, esta etapa serviu para calibrar a expectativa sobre a quantidade de informação relacionada à idade biológica do paciente que está codificada nas características morfológicas dos ventrículos laterais, fornecendo um benchmark crucial para as análises de regressão subsequentes.

3.6.2. Regressor Profundo (ResNet50)

Para a tarefa de regressão da idade a partir das imagens de ressonância magnética, foi implementado um modelo baseado na arquitetura ResNet50. A escolha deste modelo justifica-se pela sua capacidade de aprender *features* hierárquicas e não lineares diretamente dos dados de imagem, permitindo a captura de padrões sutis de atrofia cerebral relacionados ao envelhecimento que podem não ser evidentes em características manuais ou morfológicas.

A implementação consistiu em uma arquitetura utilizando um *backbone* de ResNet50 pré-treinada no conjunto de dados ImageNet, adaptada para a tarefa de regressão através de um *head* personalizado. Este *head* foi composto por uma camada de GlobalAveragePooling2D, seguida por uma camada Dense de 64 unidades com ativação ReLU e regularização L2 ($\lambda = 1e-4$), BatchNormalization, Dropout (0.5) e uma camada de saída Dense linear com uma unidade, que produz um valor contínuo correspondente à idade prevista. Uma diferença fundamental em relação ao classificador foi o uso de uma ativação linear na camada final e um *head* de dimensão reduzida, adequando a rede para uma saída de regressão.

O pré-processamento da entrada focou no *slice* axial central de cada volume cerebral NIfTI, que foi extraído e submetido às mesmas normalizações aplicadas ao classificador. Um cuidado crítico foi o alinhamento preciso entre cada imagem e a idade correta do sujeito. Para isso, um *pipeline* foi desenvolvido para extrair o Subject ID do nome

do arquivo de imagem e realizar um *merge* com os metadados clínicos, com validação rigorosa deste alinhamento antes do treinamento. Adicionalmente, o *target* (idade) foi normalizado utilizando o StandardScaler, ajustado apenas nos dados de treinamento para evitar *data leakage*, com as previsões finais sendo desnormalizadas para interpretação.

Visando melhorar a generalização do modelo em um contexto de dados médicos limitados, foi aplicado um *data augmentation* conservador, incluindo rotações de ± 5 graus, *zoom* e translação de 5%, e a adição leve de ruído gaussiano ($\text{stddev} = 0.01$). Estas transformações foram menos agressivas do que as usadas na classificação, dada a maior sensibilidade da tarefa de regressão a distorções geométricas significativas.

O treinamento foi conduzido em dois estágios para otimizar a aprendizagem e evitar o *overfitting*. Inicialmente, apenas as camadas do *head* personalizado foram treinadas, com o *backbone* congelado, por 8 épocas e uma taxa de aprendizagem de $1e - 3$. Num segundo estágio, foi realizado o *fine-tuning* das últimas aproximadamente 20 camadas do *backbone*, com uma taxa de aprendizagem reduzida para $1e - 5$ por mais 8 épocas. A função de custo empregada foi a Huber Loss, selecionada por sua robustez a *outliers*, comportando-se quadraticamente para erros pequenos e linearmente para erros grandes ($\text{delta} = 1.0$), o que a torna mais adequada do que o Erro Quadrático Médio (MSE) para esta aplicação. *Callbacks* de EarlyStopping (paciente = 3) e ReduceLROnPlateau (paciente = 2) foram utilizados para regularizar o treino.

O modelo foi avaliado com base no Erro Médio Absoluto (MAE), Raiz do Erro Quadrático Médio (RMSE) e no coeficiente de determinação (R^2), permitindo uma análise compreensiva do seu desempenho preditivo. A análise visual foi complementada com gráficos de Dispersão (Previsto vs. Real) e curvas de aprendizagem. O objetivo final deste regressor profundo é demonstrar a viabilidade de prever a idade cronológica diretamente de um único *slice* 2D de MRI, servindo como um complemento ao modelo de regressão linear baseado em características extraídas e validando o conteúdo informativo das imagens para esta tarefa biométrica.

4. Bibliotecas e Ferramentas Utilizadas

O desenvolvimento deste trabalho foi realizado utilizando a linguagem de programação Python, devido ao seu extenso ecossistema de bibliotecas voltadas para computação científica e visão computacional. Abaixo estão listadas as principais bibliotecas empregadas na implementação da solução:

- **OpenCV (Open Source Computer Vision Library)** [Bradski 2000]: Utilizada como o núcleo de processamento de imagens. Foi fundamental para a aplicação de filtros de pré-processamento (CLAHE, Gaussian Blur, Canny), conversão de espaços de cor e operações morfológicas (erosão, dilatação) na etapa de segmentação.
- **Nibabel** [Brett et al. 2020]: Empregada especificamente para a leitura e manipulação de arquivos de neuroimagem no formato NIfTI (.nii/.nii.gz), permitindo o acesso aos dados volumétricos brutos da ressonância magnética.
- **Scikit-image** [Van der Walt et al. 2014]: Utilizada na etapa de extração de características. A função `regionprops` foi essencial para calcular os descritores geométricos (área, excentricidade, solidez, extensão) das máscaras segmentadas.

- **Scikit-learn** [Pedregosa et al. 2011]: Forneceu as ferramentas para a divisão dos dados em conjuntos de treino e teste (`GroupShuffleSplit`), métricas de avaliação (matriz de confusão, acurácia, MSE) e a implementação do regressor linear.
- **XGBoost** [Chen and Guestrin 2016]: Biblioteca otimizada de *Gradient Boosting* utilizada para a implementação do classificador raso, processando os dados tabulares dos descritores extraídos.
- **TensorFlow e Keras** [Abadi et al. 2015]: Frameworks de aprendizado profundo utilizados para carregar, adaptar (via *fine-tuning*) e treinar a arquitetura ResNet50 para as tarefas de classificação e regressão baseadas em imagens.
- **NumPy** [Harris et al. 2020] e **Pandas** [pandas development team 2020]: Utilizadas, respectivamente, para operações matriciais de alto desempenho e manipulação estruturada dos dados clínicos e demográficos (arquivos CSV).
- **Matplotlib**: Utilizada para a geração dos gráficos de dispersão (*scatterplots*) e visualização das curvas de aprendizado.
- **Tkinter e Pillow (PIL)**: Utilizadas para a construção da Interface Gráfica de Usuário (GUI), permitindo a interação visual com as ferramentas de segmentação e visualização dos resultados.

5. Ambiente computacional e medidas de tempo de treinamento

Todos os experimentos foram realizados em um computador pessoal com o seguinte ambiente computacional:

- **Processador**: Intel Core i7-7700 (arquitetura Kaby Lake), 4 núcleos físicos e 8 threads, frequência base de 3.60GHz;
- **Memória RAM**: 16GB DDR4;
- **Placa de vídeo**: NVIDIA GeForce GTX 1070 Ti, com 8GB de memória dedicada;
- **Sistema operacional**: Windows 10 Pro 64 bits;
- **Linguagem e bibliotecas principais**: Python 3.x, TensorFlow/Keras com suporte a CUDA e cuDNN (para os modelos profundos), scikit-learn e XGBoost (para os modelos rasos), além de NumPy, pandas, OpenCV e *scikit-image* para pré-processamento de imagens.

Nos modelos rasos (XGBoost e Regressão Linear) o treinamento foi executado apenas em CPU, enquanto os modelos profundos com ResNet50 utilizaram a GPU para acelerar o processamento dos *batches* de imagens. A Tabela 1 resume a ordem de grandeza dos tempos de treinamento observados/estimados para cada modelo na configuração descrita.

Table 1. Tempos aproximados de treinamento dos modelos na máquina utilizada.

Tarefa / Modelo	Hardware principal	Tempo de treinamento
Classificador raso (XGBoost)	CPU	≈ 60s
Classificador profundo (ResNet50)	GPU	≈ 7min
Regressor raso (Regressão Linear)	CPU	≈ 1s
Regressor profundo (ResNet50)	GPU	≈ 3min

Observa-se que os modelos rasos treinam praticamente em tempo instantâneo para o tamanho do conjunto de dados considerado, enquanto os modelos profundos apresentam tempos de treinamento alguns minutos maiores devido ao número de parâmetros da ResNet50 e às operações de convolução sobre as imagens de ressonância magnética. Ainda assim, os tempos são compatíveis com uso em ambiente de pesquisa em um computador de mesa com GPU de médio desempenho.

6. Análise dos resultados, métricas e exemplos de erros e acertos

Esta seção apresenta a análise dos resultados obtidos pelos modelos de classificação (*Demented* vs. *NonDemented*) e de regressão de idade, explicando as métricas utilizadas e discutindo os principais padrões de acertos e erros observados. A interpretação a seguir se baseia exclusivamente nos resultados e análises geradas no sistema durante os testes.

Métricas de classificação

Para avaliar os classificadores raso (XGBoost) e profundo (ResNet50), foram utilizadas métricas padrão de problemas binários:

- **Acurácia:** mede a proporção total de exames corretamente classificados. Indica o desempenho global do modelo, mas pode mascarar problemas quando o conjunto de dados é desbalanceado.
- **Precisão** (classe *Demented*): indica, dentre os casos que o modelo previu como *Demented*, quantos realmente pertencem a essa classe. Logo, é sensível a falsos positivos.
- **Recall** ou **sensibilidade:** mede a capacidade do modelo de encontrar os casos realmente *Demented*. É diretamente afetada por falsos negativos.
- **Especificidade:** mede a capacidade do modelo de identificar corretamente os casos *NonDemented*, sendo afetada por falsos positivos.
- **F1-Score:** combina precisão e recall em um único valor, sendo útil quando há desbalanceamento entre classes, pois penaliza modelos que vão bem em apenas uma dessas medidas.
- **AUC-ROC:** resume a capacidade do classificador em separar as duas classes para diferentes valores de *threshold*. Valores próximos a 0,5 sugerem separação fraca, enquanto valores próximos de 1 indicam boa discriminabilidade.

De forma qualitativa, o classificador raso depende diretamente dos descritores morfométricos dos ventrículos, enquanto o classificador profundo tenta aprender padrões diretamente do *slice* axial central. Considerando a natureza do dataset (pequeno e desbalanceado), ambos os métodos sofrem com limitações de generalização. O modelo profundo tem maior capacidade representacional, porém fica restrito pela pouca quantidade de dados e pela diferença de domínio entre MRI e o pré-treinamento no ImageNet. Já o modelo raso é mais estável e interpretável, mas pode não capturar relações não-lineares complexas do envelhecimento patológico.

Métricas de regressão

Para avaliar a regressão de idade, foram usadas as seguintes métricas:

- **Erro Médio Absoluto (MAE):** mede o erro médio em anos entre a idade real e a predita. Quanto menor o MAE, mais próximas estão as predições do valor real.
- **Raiz do Erro Quadrático Médio (RMSE):** semelhante ao MAE, mas penaliza mais fortemente erros grandes, sendo útil para detectar predições muito distantes do real.
- **Coefficiente de determinação (R^2):** indica quanto da variância das idades reais é explicada pelo modelo. Valores próximos de 1 indicam bom ajuste; valores próximos de 0 indicam pouca explicação; valores negativos sugerem desempenho pior do que prever simplesmente a média das idades.

Nos testes do regressor profundo (ResNet50), foram obtidos: MAE de 5.74anos, RMSE de 7.34anos e $R^2 = -0.0934$. Esses valores indicam desempenho fraco para estimativa de idade, o que é coerente com a análise automatizada do sistema: o uso de apenas um *slice* axial central reduz fortemente a informação anatômica disponível, pois descarta o contexto tridimensional do volume cerebral.

No regressor raso (Regressão Linear com descritores ventriculares), o sistema também apontou limitações relevantes. Os descritores representam apenas características morfológicas dos ventrículos, que não necessariamente variam de forma direta e exclusiva com a idade cronológica. Assim, mesmo sendo uma solução interpretável, a entrada disponível tende a ser insuficiente para uma predição precisa.

Um resultado importante observado foi a verificação de monotonicidade: nenhum paciente com múltiplas visitas apresentou idade decrescente ao longo do tempo, ou seja, a idade cresceu de maneira consistente com as visitas. Isso reforça que o alinhamento exame-idade no CSV está correto e que a falha de desempenho na regressão não se deve a erros de rotulagem.

Comparação entre as soluções

A comparação entre métodos rasos e profundos mostra um contraste esperado:

- **Modelos rasos** (XGBoost e Regressão Linear): são rápidos, fáceis de treinar e interpretar, mas dependem totalmente de descritores manuais. Se esses descritores não capturam bem o fenômeno (como no caso da idade), o desempenho fica naturalmente limitado.
- **Modelos profundos** (ResNet50): têm potencial para capturar padrões mais ricos diretamente das imagens, porém, neste trabalho, ficaram limitados por três fatores centrais: (i) tamanho reduzido do dataset, (ii) uso de apenas uma fatia 2D em vez do volume 3D, e (iii) diferença de domínio entre imagens naturais (ImageNet) e MRI.

Portanto, apesar da maior flexibilidade representacional do *deep learning*, as condições atuais de entrada e dados impediram ganhos claros na regressão de idade, e exigem cautela na interpretação de desempenho na classificação.

Exemplos qualitativos de erros e acertos

Na classificação, observou-se que casos com alterações ventriculares mais marcadas tendem a ser mais facilmente identificados como *Demented*, enquanto situações borderline (por exemplo, quadros leves ou iniciais) são mais propensas a erro, pois os ventrículos ainda podem ter morfologia próxima à de pacientes *NonDemented*. Isso afeta principalmente a sensibilidade (falsos negativos).

Falsos positivos também são plausíveis quando um paciente não demente apresenta ventriculomegalia por outras razões anatômicas ou clínicas, confundindo o modelo raso por depender do tamanho e forma dessa estrutura.

Na regressão de idade, o padrão global indica baixa capacidade de generalização, com erros médios de vários anos. Isso sugere que a idade não está suficientemente representada nem pelos descritores ventriculares nem por um único *slice* axial, reforçando a necessidade futura de múltiplos *slices* ou abordagem 3D para capturar sinais mais consistentes de envelhecimento cerebral.

Em síntese, os resultados confirmam que o pipeline está correto e funcional, porém as entradas atuais são limitadas para predições altamente precisas, especialmente na tarefa de regressão de idade.

References

- Abadi, M. et al. (2015). TensorFlow: Large-scale machine learning on heterogeneous systems. Software available from tensorflow.org.
- Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*.
- Brett, M., Markiewicz, C. J., Hanke, M., et al. (2020). nipy/nibabel.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, New York, NY, USA. ACM.
- Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585:357–362.
- pandas development team, T. (2020). pandas-dev/pandas: Pandas.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Van der Walt, S., Schönberger, J. L., Nunez-Iglesias, J., Boulogne, F., Warner, J., Yager, N., Gouillart, E., and Yu, T. (2014). scikit-image: image processing in Python. *PeerJ*, 2:e453.